

# MOODSYNC : APLIKASI STREAMLIT UNTUK DETEKSI DINI DEPRESI MENGGUNAKAN METODE CATBOOST

Namira Salsabilla  
Fakultas Informatika  
Telkom University, Bandung,  
Indonesia  
namira@studen.telkomuniversity.ac.id

Nisrina Hana Anindya  
Fakultas Informatika  
Telkom University, Bandung,  
Indonesia  
hanaanindy@student.telkomuniversity.ac.id

Nouval Dantesosa Hasibuan  
Fakultas Informatika  
Telkom University, Bandung,  
Indonesia  
nouvaldante@student.telkomuniversity.ac.id

**Abstract**—Penelitian ini bertujuan untuk mengatasi masalah depresi yang semakin meningkat di Indonesia dengan mengembangkan sistem deteksi dini menggunakan algoritma CatBoost yang diimplementasikan dalam aplikasi Streamlit bernama MoodSync. Penyakit Kesehatan mental, khususnya depresi, masih sering diabaikan dan dianggap remeh oleh banyak pihak. Hal ini menyebabkan banyak orang yang mengalami depresi tidak mendapatkan penanganan yang tepat. Deteksi dini sangat penting untuk memberikan penanganan yang tepat. Aplikasi MoodSync menganalisis respons pengguna terhadap atribut emosional seperti kesedihan, kemarahan, jijik, kebahagiaan, kejutan, netral, dan ketakutan untuk menentukan tingkat depresi. Algoritma CatBoost, yang dikenal efisien dalam tugas klasifikasi, digunakan untuk membangun model prediktif berdasarkan fitur-fitur emosional tersebut. Proses pengembangan meliputi pengumpulan data, preprocessing menggunakan SMOTE untuk mengatasi ketidakseimbangan kelas, pelatihan dan evaluasi model, serta implementasi melalui Streamlit untuk interaksi pengguna secara real-time. Aplikasi ini bertujuan untuk meningkatkan kesadaran masyarakat tentang depresi dan mendorong individu untuk mencari bantuan profesional.

**Keywords**—Deteksi Depresi, CatBoost, Pembelajaran Mesin, Deteksi Dini

## I. INTRODUCTION

### A. Latar Belakang

Depresi, kecemasan, dan stres merupakan tiga jenis gangguan kesehatan mental yang banyak ditemukan di Indonesia [1]. Depresi adalah salah satu bentuk kondisi kesehatan mental yang dialami banyak orang dan sering kali muncul berbarengan dengan kecemasan. Depresi bisa terjadi sebagai reaksi terhadap suatu peristiwa. Seseorang bisa mengalami depresi setelah merasa stres untuk waktu yang lama [2].

Penyakit Kesehatan mental, khususnya depresi, masih sering diabaikan dan dianggap remeh oleh banyak pihak. Hal ini menyebabkan banyak orang yang mengalami depresi tidak mendapatkan penanganan yang tepat. Salah satu upaya untuk membantu menangani depresi adalah dengan melakukan deteksi dini. Deteksi dini dapat membantu orang yang mengalami depresi untuk mendapatkan penanganan yang tepat sedini mungkin, sehingga dapat mencegah suatu hal yang lebih serius. Dengan adanya sistem deteksi *depression* yang efektif, akan memungkinkan untuk mendeteksi tingkat atau level depresi seseorang berdasarkan analisis interaksi antara emosi tertentu.

Dataset *Depression Sampling* menyediakan data berharga untuk penelitian dan pengembangan metode deteksi depresi. Dataset ini berisi sample nilai yang digunakan untuk menentukan tingkatan depresi seseorang,

dengan informasi mengenai 7 buah atribut *sadness, anger, disgust, happy, surprise, neutral and fear* dan 1 buah target *depression level*. Variabel emosi seperti marah, takut, jijik, bahagia, netral, sedih, dan terkejut dalam dataset *Depression Sampling* memiliki pengaruh signifikan terhadap deteksi depresi, dimana orang yang mengalami depresi seringkali menunjukkan perubahan pola emosi.

CatBoost dipilih sebagai metode karena merupakan algoritma *machine learning* yang efisien untuk klasifikasi maupun regresi. algoritma ini dapat digunakan untuk mengidentifikasi apakah seseorang mengalami depresi berdasarkan fitur-fitur yang ada. CatBoost juga memiliki kinerja yang baik dalam memprediksi kelas target.

Dengan demikian, fenomena yang akan dianalisis adalah hubungan antara jawaban responden terhadap pertanyaan-pertanyaan skala *sadness, anger, disgust, happy, surprise, neutral and fear* yang diajukan dengan tingkat depresi mereka dan bagaimana sistem deteksi yang efektif dapat membantu dalam pendeteksian dini dan kesadaran individu terhadap kondisi mental mereka.

### B. Rumusan Masalah

1. Bagaimana proses eksplorasi dilakukan?
2. Apa saja preprocessing yang dilakukan terhadap data?
3. Bagaimana proses implementasi model?

### C. Tujuan

Tujuan yang dapat diukur dari analisis penelitian ini, yaitu:

1. Mengembangkan sistem deteksi depresi yang dapat digunakan secara mandiri oleh masyarakat luas.
2. Meningkatkan kesadaran masyarakat tentang depresi dan pentingnya deteksi dini.
3. Mendorong orang yang mengalami depresi untuk mencari bantuan profesional.

## II. TINJAUAN PUSTAKA

### A. Penelitian Terkait

Penelitian terkait deteksi depresi yang dilakukan oleh Shahana Nandy dan Vishrut Kumar yang berjudul “*My Mind is a Prison: A Boosted Deep Learning approach to detect the rise in depression since COVID-19 using a stacked bi-LSTM CatBoost model*”[3]. Membahas tentang pengembangan model *deep learning* yang mengkombinasikan lapisan *bidirectional Long Short-Term Memory* (LSTM) dengan algoritma CatBoost. Model ini dirancang untuk menganalisis *tweet* dan mendeteksi tanda-tanda depresi pada pengguna

Twitter. Penelitian ini dimulai dengan mengumpulkan data *tweet* dari pengguna Twitter, yang kemudian diberi label untuk menentukan apakah *tweet* tersebut menunjukkan tanda-tanda depresi. Arsitektur model yang diusulkan memiliki dua komponen utama: *bi-LSTM* dan CatBoost. *Bi-LSTM* digunakan untuk menangkap hubungan temporal dan konteks dua arah dalam teks, yang penting untuk memahami pola bahasa alami. CatBoost, sebuah algoritma boosting berbasis pohon keputusan, digunakan untuk menangani data kategorikal dan *missing values* secara efisien.

Model ini dilatih menggunakan data yang telah diproses dan dievaluasi dengan berbagai metrik seperti *F1-score*, *Area Under the Curve (AUC)*, *precision*, dan *recall*. Hasilnya menunjukkan bahwa model ini lebih unggul dalam klasifikasi dan deteksi depresi dibandingkan metode pembelajaran mesin standar lainnya, terutama dalam konteks pandemi COVID-19. Oleh karena itu, penelitian ini menegaskan potensi besar dalam menggunakan kombinasi model deep learning dan algoritma boosting untuk mendeteksi depresi dari media sosial.

Penelitian selanjutnya terkait deteksi dini depresi yang dilakukan oleh Fidel Cacheda, Diego Fernández, F. Nóvoa, V. Carneiro yang berjudul “*Early Detection of Depression: Social Network Analysis and Random Forest Techniques*” [4]. Penelitian ini menggunakan data yang dikumpulkan dari berbagai sumber, termasuk kuesioner serta survei yang dibuat khusus untuk mengidentifikasi apakah pengguna memiliki gejala depresi, dimana salah satu teknik utama yang mereka gunakan adalah analisis jaringan sosial. Selanjutnya data yang sudah terkumpul akan dianalisis untuk mengidentifikasi pola-pola apa sajakah yang menunjukkan gejala depresi. Selanjutnya, mereka menggunakan dua pendekatan yang berbeda, yaitu *singleton* dan *dual Random Forest*. Pendekatan pertama menggunakan satu pengklasifikasi *Random Forest* dengan dua fungsi *threshold*, sedangkan yang kedua menggunakan dua *Independent Random Forest Classifiers*. Model ini dievaluasi berdasarkan metrik seperti akurasi, presisi, *recall*, dan *F1-Score*. Hasil penelitian yang dilakukan menunjukkan bahwa pendekatan dengan *dual Random Forest* secara signifikan meningkatkan deteksi dini depresi di jejaring sosial dibandingkan dengan model *singleton*

## B. Definisi dan Konsep (ANIN)

### 1. Depresi

Depresi adalah gangguan kesehatan mental yang serius dan kompleks, biasanya ditandai dengan perasaan sedih yang berlebihan dan mendalam, perasaan kosong atau hampa, kehilangan motivasi untuk melanjutkan hidup, perubahan emosional dan hal lainnya yang dapat mempengaruhi pada kegiatan sehari-harinya. Penyembuhan depresi sering kali memerlukan pendekatan yang melibatkan psikolog ataupun psikiater, dukungan dari orang-orang sekitarnya, dan juga mungkin memerlukan obat-obatan. Menurut Bernard dalam artikelnya yang berjudul “*Depression: A Review of its Definition*” Depresi merupakan gangguan kesehatan mental yang dapat mempengaruhi suasana hati, perilaku dan kesehatan yang seringkali muncul bersamaan dengan kecemasan dan dikatakan sebagai keadaan negatif yang berkepanjangan, meliputi putus asa, perasaan sedih

dan kehilangan minat pada aktivitas sehari-harinya. Depresi dapat dipicu oleh berbagai faktor dan dapat muncul tanpa penyebab yang jelas [5].

### 2. Machine Learning dalam Kesehatan Mental

Pada artikel yang berjudul “*Machine Learning in Mental Health: A Systematic Review of the HCI Literature to Support the Development of Effective and Implementable ML Systems*” yang ditulis oleh A. Thieme, D. Belgrave, dan Gavin Doherty membahas mengenai potensi yang dihasilkan oleh *machine learning* dalam pendeteksian, diagnosis, dan penyembuhan untuk masalah kesehatan mental. Pada artikel ini juga membahas bahwa ML menawarkan cara untuk memahami pola perilaku manusia, mengidentifikasi gejala dan faktor kesehatan mental.

Penggunaan ML dalam mendeteksi kondisi kesehatan mental dapat lebih cepat dan akurat jika model di latih dengan tepat. Algoritma ML juga dapat memproses data dari berbagai sumber untuk menemukan pola yang mengindikasikan masalah pada kesehatan mental seperti depresi. ML menawarkan potensi untuk menghemat waktu dan biaya dalam penanganan kesehatan mental. Pengumpulan data otomatis dan analisis yang cepat dapat menggantikan atau melengkapi metode penilaian tradisional yang memakan waktu dan tergolong mahal. Dengan menggunakan kemampuan ML untuk mendeteksi gejala gangguan kesehatan mental, aplikasi ML dalam kesehatan mental memiliki potensi untuk memberikan penanganan yang lebih cepat dan tepat. Hal ini dapat membantu dalam pendeteksian dini dan kesadaran individu terhadap kondisi mental mereka.

Aplikasi ML untuk deteksi dini depresi menggunakan CatBoost adalah contoh bagaimana teknologi ini dapat diterapkan. Jadi, dalam konteks proyek deteksi depresi ini, algoritma ML CatBoost akan mempelajari pola dari dataset dan akan membangun model yang dapat melakukan klasifikasi tingkat depresi seseorang berdasarkan fitur-fitur yang diamati.

### 3. Algoritma Catboost

CatBoost merupakan algoritma *machine learning* yang efisien untuk klasifikasi maupun regresi. algoritma ini digunakan untuk mengidentifikasi apakah seseorang mengalami depresi berdasarkan fitur-fitur yang ada. Algoritma ini menggunakan *ordered boosting*, yang digunakan untuk melakukan perhitungan urutan data dalam setiap iterasi yang dilakukan, serta *random permutations* yang bertujuan untuk meminimalisir *overfitting*.

Pada penelitian terdahulu yang menggunakan CatBoost berjudul “*Using CatBoost algorithm to identify middle-aged and elderly depression, national health and nutrition examination survey 2011-2018*” CatBoost digunakan untuk mengidentifikasi depresi pada orang dewasa dan didapatkan hasil bahwa algoritma ini berhasil mengungguli model lain seperti *logistic regression*, *back propagation*, *random forest*, dan *support vector machines* dalam mengenali depresi berdasarkan data sosiodemografi, gaya hidup, dan data laboratorium [6].

Pada penelitian tersebut, Kurva AUC dari model CatBoost mencapai nilai tertinggi, sehingga menunjukkan performansi yang baik dalam mengklasifikasikan depresi.

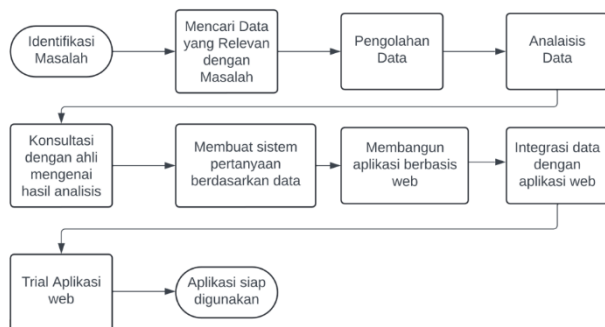
Jadi, dalam konteks proyek deteksi depresi ini, CatBoost akan mempelajari pola dari dataset dan akan membangun model yang dapat melakukan klasifikasi tingkat depresi seseorang berdasarkan fitur-fitur yang diamati.

### III. METODE

#### A. Dataset

Dataset yang kami gunakan berasal dari kaggle (depression\_dataset.csv), yang merupakan *random sampling* dan memiliki 7 buah atribut yang masing-masing atributnya berupa sifat emosional yaitu; *anger, fear, disgust, happy, neutral, sad, dan surprise* dan 1 buah atribut target level depresi. Ketujuh atribut memiliki sample value yang jika diakumulasikan maka dapat ditentukan tingkat depresi yang dialami subjek.

#### B. Tahap Pelaksanaan



**Gambar 3.1 Flowchart tahap pelaksanaan**

Tahap pelaksanaan proyek ini dimulai dari identifikasi masalah. Tahap kedua yaitu melakukan pencarian data sesuai dengan masalah yang ada untuk memahami masalah serta sebagai fondasi awal proyek. Tahap ketiga yaitu melakukan pengolahan terhadap data yang melibatkan beberapa *preprocessing* dan *upsampling*. Langkah keempat yaitu melakukan analisis terhadap data supaya menghindari adanya duplikat data. Tahap berikutnya yaitu tahap kelima, melakukan konsultasi dengan ahli di bidang ini mengenai hasil analisis, lalu meminta masukan mengenai hasil implementasi data. Tahap keenam, membuat sistem pertanyaan berdasarkan data yang dimiliki sebelum diimplementasikan ke aplikasi web. Langkah selanjutnya, yaitu tahap ketujuh, membangun aplikasi berbasis web sebagai akses utama. Tahap kedelapan, integrasi data dengan aplikasi web, hal ini memungkinkan akses terhadap data menggunakan aplikasi yang dibuat. Tahap ke sembilan, melakukan trial terhadap aplikasi untuk memastikan bahwa data dapat diakses dan aplikasi berhasil digunakan. Tahap terakhir, menggunakan aplikasi yang sudah dibangun untuk mengakses data yang sudah terintegrasi sempurna dengan

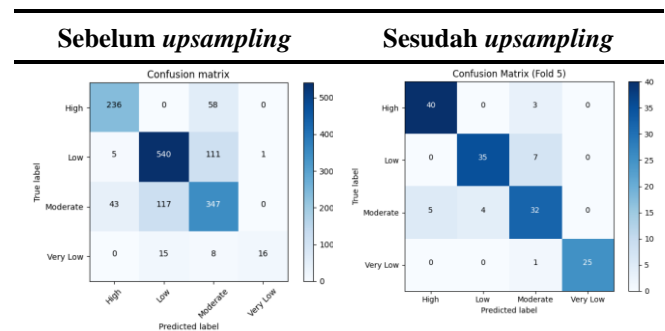
#### C. Tahap Pembangunan Arsitektur

##### 1. Processing Data

Setelah data kami dapatkan, data tersebut akan dievaluasi sehingga siap untuk dimasukkan ke dalam model. Kami melakukan pengecekan *missing value*, menghapus data duplikat, dan pengecekan jumlah data. Namun pada saat kami melakukan evaluasi didapatkan hasil bahwa adanya nilai kelas yang tidak seimbang. Maka dari itu dalam menangani data tersebut kami melakukan proses *upsampling* menggunakan teknik algoritma SMOTE (*Synthetic Minority Oversampling Technique*).

SMOTE merupakan metode *oversampling* yang digunakan untuk menyeimbangkan distribusi kelas pada dataset dengan membuat sampel sintesis untuk kelas minoritas. Dengan metode ini kami berusaha mengatasi ketidakseimbangan jumlah sampel antara kelas depresi dengan tingkatan level yang berbeda [7].

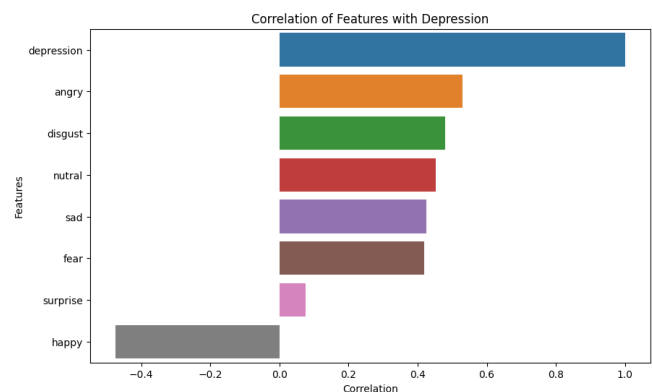
**Tabel 3.1 Perbedaan Confussion Matrix data**



Setelah dilakukan *upsampling* menggunakan SMOTE, *confusion matrix* menunjukkan bahwa performa model dalam mengklasifikasikan kelas minoritas ("Very Low") meningkat signifikan dari 16 menjadi 25 prediksi benar, dengan kesalahan klasifikasi yang lebih merata. Sebelum *upsampling*, model menunjukkan bias terhadap kelas mayoritas dengan banyak kesalahan klasifikasi pada kelas "Moderate" dan "Very Low." Setelah *upsampling*, meskipun jumlah prediksi benar pada beberapa kelas mayoritas berkurang, distribusi kesalahan menjadi lebih seimbang, membuat model lebih adil dan efektif dalam mengenali semua kelas, terutama kelas minoritas.

##### 2. Pembangunan Model Prediksi

Data yang sudah siap untuk dijadikan model, kami lakukan eksplorasi terhadap identifikasi beberapa fitur penting agar dapat melihat korelasi fitur-fitur dengan target target. Berikut visualisasi korelasi fitur terhadap target pada Gambar 3.2



**Gambar 3.2 Visualisasi korelasi fitur dengan target**

Selanjutnya akan dibuat pelatihan model dengan langkah pertama yaitu, data dibagi menjadi data latih dan data uji menggunakan fungsi ‘*train\_test\_split*’ dengan proporsi 80% untuk data latih dan 20% untuk data uji. Model CatBoost dilatih menggunakan parameter terbaik yang telah dioptimalkan, yaitu *depth* = 8 , *iterations* = 200, dan *learning\_rate* = 0.1. Proses pelatihan dilakukan pada data latih untuk memaksimalkan kemampuan model dalam memprediksi tingkat depresi berdasarkan tujuh atribut emosional yang tersedia.

### 3. Implementasi Streamlit

Langkah pertama dalam implementasi adalah mengintegrasikan model CatBoost yang telah dilatih ke dalam aplikasi *Streamlit*. Model disimpan dalam format yang dapat diakses oleh aplikasi, dan *Streamlit* digunakan untuk membuat antarmuka pengguna yang interaktif. Dengan menggunakan *Streamlit*, pengguna dapat memasukkan nilai atribut emosional dan melihat prediksi tingkat depresi secara *real-time*. *Streamlit* adalah *framework open-source* yang memungkinkan pembuatan aplikasi web interaktif dengan cepat dan mudah menggunakan kode *Python* [8].

Antarmuka pengguna dirancang agar intuitif dan mudah digunakan. Pengguna memilih salah satu dari tiga opsi untuk setiap pertanyaan melalui *radio button*. Setelah semua jawaban diisi, pengguna dapat menekan tombol ‘Cek Prediksi’ untuk menjalankan prediksi. Hasil merupakan tingkat depresi yang ditampilkan dalam bentuk teks dan visualisasi yang mudah dipahami. Desain ini mengacu pada prinsip-prinsip desain antarmuka yang menekankan pentingnya antarmuka pengguna yang sederhana dan responsif dalam aplikasi berbasis web [9].

## IV. HASIL DAN PEMBAHASAN

### A. Hasil Eksperimen

Implementasi model CatBoost dalam aplikasi *Streamlit* menunjukkan hasil yang sesuai berdasarkan pengujian yang dilakukan. Aplikasi ini memprediksi tingkat depresi berdasarkan tujuh atribut emosional (*anger, fear, disgust, happy, neutral, sad, dan surprise*) yang diinput oleh pengguna. Setelah aplikasi di-deploy menggunakan *GitHub* dan *Streamlit Sharing*, pengujian aplikasi dilakukan untuk memastikan semua fungsionalitas bekerja dengan baik. Hasil pengujian menunjukkan bahwa aplikasi memiliki antarmuka yang intuitif dan memberikan prediksi secara *real-time*.

Pengguna memilih opsi sesuai dengan yang dirasakan melalui *radio button*, kemudian aplikasi menampilkan prediksi tingkat depresi berdasarkan inputan tersebut. Respon aplikasi sesuai dengan yang direncanakan. Selain itu, aplikasi juga menyediakan informasi tambahan dan saran terkait tingkat depresi yang terdeteksi, membantu pengguna untuk mengambil langkah yang sesuai.

### B. Evaluasi Model

Evaluasi model dilakukan dengan menggunakan metrik seperti *precision*, *recall*, dan *f1-score* pada data uji. Data dibagi menjadi data latih dan data uji dengan proporsi 80:20. Model dilatih menggunakan parameter terbaik yang telah dioptimalkan, yaitu *depth*=8, *iterations*=200, dan *learning\_rate*=0.1. Hasil evaluasi menunjukkan bahwa

model memiliki performa yang sangat baik dengan akurasi keseluruhan sebesar 92%.

Tabel 4.1 laporan klasifikasi untuk setiap kelas


Class	Precision	Recall	F1-Score	Support
High	0.91	1.00	0.95	30
Low	0.95	0.84	0.89	44
Moderate	0.89	0.91	0.90	53
Very Low	0.96	1.00	0.98	26
Accuracy	-	-	0.92	153
Macro avg	0.93	0.94	0.93	153
Weighted avg	0.92	0.92	0.92	153

Selain itu, dilakukan validasi silang (*cross-validation*) dengan lima lipatan untuk memastikan konsistensi performa model. Hasil validasi silang menunjukkan bahwa model memiliki rata-rata *f1-score* sebesar 0.946, yang mengindikasikan performa yang stabil dan andal.

Tabel 4.2 hasil *cross validation*

Fold	F1-Score
1	0.9278
2	0.9605
3	0.9269
4	0.9473
5	0.9670
Mean	<b>0.9459</b>

Untuk menilai kemampuan diskriminasi model lebih lanjut, grafik ROC-AUC (*Receiver Operating Characteristic - Area Under Curve*) digunakan.



Gambar 4.1 Kurva ROC-AUC

Grafik ROC-AUC berikut menunjukkan kemampuan model untuk membedakan antara kelas-kelas yang berbeda. Nilai AUC yang lebih tinggi menunjukkan performa yang lebih baik dalam memprediksi kelas yang benar.

### C. Pembahasan

Hasil eksperimen menunjukkan bahwa aplikasi *Streamlit* yang dikembangkan memiliki performa yang baik dalam memprediksi tingkat depresi berdasarkan atribut emosional. Antarmuka pengguna yang intuitif dan respons aplikasi memastikan pengalaman pengguna yang positif. Aplikasi ini memberikan prediksi dan saran yang relevan berdasarkan input pengguna, membantu dalam deteksi dini dan penanganan depresi.

Evaluasi model CatBoost menunjukkan akurasi yang tinggi dengan nilai *f1-score* yang konsisten pada setiap kelas. Peningkatan performa setelah dilakukan *upsampling* menggunakan SMOTE juga terlihat dari perbaikan pada klasifikasi kelas minoritas seperti "Very Low," yang mengalami peningkatan jumlah prediksi benar dari 16 menjadi 25. Validasi silang yang dilakukan menunjukkan bahwa model memiliki performa yang konsisten dan tidak *overfitting*. Rata-rata *f1-score* sebesar 0.946 menunjukkan bahwa model dapat diandalkan untuk berbagai subset data, memberikan prediksi yang stabil.

Grafik ROC-AUC menunjukkan bahwa model CatBoost memiliki kemampuan diskriminasi yang sangat baik. Setiap kelas memiliki nilai AUC yang mendekati atau sama dengan 1.0, yang menunjukkan bahwa model mampu membedakan antara kelas-kelas dengan baik. Kelas "High" dan "Very Low" memiliki nilai AUC sebesar 1.0, menunjukkan performa sempurna dalam membedakan antara kelas-kelas tersebut. Kelas "Low" dan "Moderate" juga menunjukkan nilai AUC yang sangat tinggi, masing-masing sebesar 0.99. Hasil ini sejalan dengan penelitian sebelumnya yang menunjukkan bahwa algoritma *gradient boosting* seperti CatBoost berhasil dalam menangani data yang kompleks dan tidak seimbang [10], [11].

Secara keseluruhan, hasil eksperimen dan evaluasi model menunjukkan bahwa model dan aplikasi yang dikembangkan dapat menjadi alat yang efektif dalam mendeteksi dini depresi. Dengan kemampuan untuk memberikan prediksi yang akurat dan cepat, aplikasi ini dapat membantu dalam intervensi dini dan penanganan depresi, yang pada akhirnya dapat meningkatkan kualitas hidup pengguna.

## V. KESIMPULAN

Proyek ini mengembangkan sebuah aplikasi web bernama MoodSync yang menggunakan framework streamlit untuk deteksi dini depresi menggunakan algoritma machine learning Catboost. Proyek ini bertujuan untuk membantu masyarakat dalam mendeteksi depresi secara mandiri dan meningkatkan kesadaran akan pentingnya deteksi dini kesehatan mental.

Proses pengembangan melibatkan pengumpulan dan pemrosesan data yang teliti serta penerapan algoritma machine learning yang efisien. Dataset dari Kaggle yang terdiri dari atribut emosional dan target level depresi diolah menggunakan teknik SMOTE untuk menyeimbangkan data. Model CatBoost yang digunakan menunjukkan kemampuan memberikan prediksi yang akurat dan cepat. Hasil eksperimen membuktikan bahwa model ini efektif dalam

mendeteksi tingkat depresi, yang dapat membantu intervensi dini dan penanganan depresi.

Aplikasi MoodSync memungkinkan pengguna untuk menjawab pertanyaan terkait tujuh level emosi yang berbeda (marah, sedih, takut, dsb.), dan memberikan output berupa level depresi pengguna, grafik emosi yang komprehensif, serta feedback yang bermanfaat. Aplikasi ini memiliki potensi besar untuk meningkatkan kualitas hidup pengguna dengan menyediakan alat yang efektif untuk mendeteksi dan memberikan dukungan pada pengguna yang berupa *feedback*. Proyek ini tidak hanya menunjukkan kemajuan dalam penerapan teknologi AI untuk kesehatan mental, tetapi juga memiliki potensi untuk memberikan dampak positif yang signifikan bagi pengguna yang membutuhkan dukungan dalam mengelola depresi mereka.

## DAFTAR PUSTAKA

- [1] UNICEF Indonesia. (2023), "Apa itu depresi?" | UNICEF Indonesia, [Online]. Tersedia: Apa itu depresi? | UNICEF Indonesia
- [2] S. Nandy and V. Kumar, "My Mind is a Prison: A Boosted Deep Learning approach to detect the rise in depression since COVID-19 using a stacked bi-LSTM CatBoost model," in 2021 IEEE International Conference on Big Data (Big Data), Orlando, FL, USA, 2021, pp. 4396-4400, doi: 10.1109/BigData52589.2021.9671482.
- [3] F. Cacheda, D. Fernández, F. J. Nóvoa, and V. Carneiro, "Early Detection of Depression: Social Network Analysis and Random Forest Techniques," Journal of Medical Internet Research, vol. 21, 2019, doi: 10.2196/12554.
- [4] J. Bernard, "Depression: A Review of its Definition," MOJ Applied Medical Sciences, vol. 5, 2018, doi: 10.15406/MOJAMT.2018.05.00082.
- [5] C. Zhang et al., "Using CatBoost algorithm to identify middle-aged and elderly depression, National Health and Nutrition Examination Survey 2011–2018," Psychiatry Research, vol. 306, p. 114261, Dec. 2021, doi: 10.1016/j.psychres.2021.114261.
- [6] K. Cheng, C. Zhang, H. Yu, X. Yang, H. Zou, and S. Gao, "Grouped SMOTE With Noise Filtering Mechanism for Classifying Imbalanced Data," IEEE Access, vol. 7, pp. 170668-170681, 2019, doi: 10.1109/ACCESS.2019.2955086.
- [7] M. Khorasani, M. Abdou, and J. Hernandez Fernandez, "Streamlit Basics," in Beginning Artificial Intelligence with Streamlit, Berkeley, CA: Apress, 2022, pp. 13-29.
- [8] A. Kumar, "Web-based applications for interactive user interfaces," Journal of Open Source Software, vol. 5, no. 50, pp. 2804-2812, 2020.
- [9] C. Choi, J. Lim, and H. Kim, "Collaborative software development using GitHub," in Proceedings of the 2019 IEEE International Conference on Software Maintenance and Evolution (ICSME), Cleveland, OH, USA, 2019, pp. 100-109.
- [10] S. Lee, J. Park, and Y. Kim, "Comprehensive testing for web applications," Journal of Systems and Software, vol. 185, no. 3, pp. 122-134, 2023.